

Evalúa el impacto de tu proyecto de innovación educativa

Día 2: Pilotaje y análisis de resultados

25 de junio de 2026

Apertura del Día 2

Agenda de hoy:

Horario	Bloque
9:00 – 9:20	Apertura, recap y cosecha de la línea base
9:20 – 12:00	Módulo 3: Pilotaje y recopilación de datos
12:00 – 13:00	Práctica con Claude Code: análisis inferencial
13:00 – 14:00	Comida
14:00 – 16:00	Módulo 5: Análisis e interpretación de resultados
16:00 – 18:00	Asíncrono: Mapa de análisis pre-registrado (Plantilla 4, Sección 3)

Recap del Día 1

Lo que construiste ayer:

- ▶ **Plantilla 1:** Instrumento revisado: criterios observables, sin problemas de validez identificados
- ▶ **Plantilla 2:** Cadena coherente (brecha → objetivo → indicador → instrumento → umbral) + línea base documentada

Hoy:

- ▶ Cómo implementar el piloto con rigor
- ▶ Cómo diseñar el análisis ANTES de ver los datos (pre-registro)

Cosecha de la línea base

Pregunta al plenario:

¿Qué fue lo más sorprendente de buscar tu línea base?

(En el chat, 3 minutos)

Módulo 3: Pilotaje y recopilación de datos (9:20 – 12:00)

Módulo 3: Lo que vas a construir

Entregable: Plan de pilotaje y protocolo de recopilación (Plantilla 3)

Al terminar el módulo serás capaz de:

- ▶ Diseñar un cronograma de piloto de 16 semanas con roles definidos
- ▶ Establecer un protocolo de comunicación con los estudiantes
- ▶ Diseñar el protocolo de recopilación de datos
- ▶ Iniciar la bitácora de pilotaje

¿Qué es un piloto riguroso?

Piloto implementación sin más.

Un piloto riguroso tiene:

1. **Cronograma definido** con fechas concretas de inicio, medición y cierre
2. **Roles claros** para quién hace qué durante la implementación
3. **Protocolo de recopilación** que especifica cuándo y cómo se recogerán los datos
4. **Bitácora** para registrar lo que ocurre y los ajustes al diseño
5. **Protocolo ético** de comunicación con los estudiantes

Sin estas cinco piezas, el piloto producirá datos pero no sabrás si son confiables.

El cronograma del piloto: 16 semanas

Estructura típica de un semestre:

Semanas	Fase	Qué ocurre
1	Pre-medición	Aplicar línea base / pre-test antes de la intervención
2-4	Implementación inicial	Primeras sesiones de la intervención; ajustes
5-8	Implementación central	El núcleo de la intervención; medición formativa
9-12	Implementación de cierre	Sesiones finales; pre-aviso de post-medición
13-14	Post-medición	Aplicar instrumento principal y secundario
15-16	Análisis y cierre	Organizar datos; primer borrador de resultados

Asignación de roles

En un proyecto unidocente, los roles siguen siendo necesarios:

Rol	Descripción	¿Quién?
Implementador	Imparte las sesiones de la intervención	El docente
Evaluador	Aplica y califica los instrumentos	El docente + (opcionalmente) un colega calibrador
Recopilador de datos	Descarga, organiza y resguarda los datos	El docente (o asistente de investigación)
Analizador	Realiza el análisis descriptivo básico	El docente
Comunicador	Mantiene al grupo informado sobre el proyecto	El docente

Si hay un co-investigador o asistente, documentar su rol explícitamente, ya que importa para la sección de autoría si hay publicación.

Protocolo de comunicación con los estudiantes

Lo mínimo que los estudiantes deben saber:

1. **Qué está cambiando** en el curso y por qué
2. **Qué datos se van a recoger** y para qué propósito
3. **Que su participación no afecta la calificación** (repetirlo explícitamente)
4. **Cómo acceder a sus propios datos** si lo solicitan
5. **Con quién hablar** si tienen dudas o incomodidades

Cuándo comunicarlo: en la primera sesión del semestre, con el consentimiento.

El protocolo de recopilación de datos

Cinco preguntas que debe responder:

1. ¿Qué instrumento se aplica? (nombre exacto del instrumento y versión)
2. ¿Quién lo aplica? (docente, plataforma, estudiante mismo)
3. ¿Cuándo se aplica? (semana, sesión, momento dentro de la sesión)
4. ¿Cómo se almacenan los datos? (carpeta, hoja de cálculo, plataforma)
5. ¿Quién tiene acceso a los datos sin anonimizar?

El protocolo debe estar documentado antes de empezar la recopilación, no después.

La bitácora: el registro del piloto

¿Para qué sirve la bitácora?

- ▶ Registra los ajustes al diseño original y sus razones
- ▶ Documenta eventos inesperados que podrían afectar los resultados
- ▶ Es la materia prima para la sección de “limitaciones” del informe
- ▶ Permite el ciclo PDSA (Plan-Do-Study-Act) durante la implementación

¿Qué registrar en cada sesión?

- ▶ ¿La sesión ocurrió como estaba planeada?
- ▶ ¿Hubo algo inesperado (técnico, pedagógico, de participación)?
- ▶ ¿Qué ajuste se hará en la siguiente sesión y por qué?

Actividad: Plan de pilotaje (10:00 – 11:30)

Plantilla 3: Secciones 1 a 6

Trabajo individual: 90 minutos

- 1. Sección 1 (15 min):** Cronograma: llena las fechas clave (pre-medición, implementación, post-medición)
- 2. Sección 2 (10 min):** Roles: define quién hace qué, aunque seas el único
- 3. Sección 3 (15 min):** Protocolo de comunicación con estudiantes: adapta el borrador
- 4. Sección 4 (25 min):** Protocolo de recopilación: responde las 5 preguntas para cada instrumento
- 5. Sección 5 (15 min):** Bitácora: llena la primera entrada con lo que ya sabes del piloto previo (si lo tienes)
- 6. Sección 6 (10 min):** Herramienta de seguimiento: define las 3 variables y dónde vivirán

90 min

Sala de trabajo: revisión del plan (11:30 – 12:00)

Equipos de 3 personas (distintos al par del día anterior)

En la sala (20 minutos):

1. Cada persona presenta su cronograma y señala la fecha de pre-medición (1 min c/u)
2. El equipo identifica: ¿hay alguna fecha que sea claramente problemática? (semana de exámenes, semanas festivas, etc.)
3. Cada persona recibe una sugerencia de ajuste

Cosecha en plenario (10 min):

¿Qué ajuste fue el más valioso? (en el chat)

30 min

Práctica con Claude Code (12:00 – 13:00)

Práctica: análisis inferencial con Claude Code

Con `rubrica_argumentacion.csv` en tu carpeta de trabajo

Usa los prompts del archivo `prompts_analisis_inferencial.md` en el orden sugerido:

1. **Prompt 1 (10 min):** Exploración inicial — familiarízate con el dataset
2. **Prompt 3 (15 min):** t pareada + Wilcoxon + d de Cohen para el grupo intervención
3. **Prompt 5 (15 min):** DiD con gráfica de barras agrupadas
4. **Prompt 6 (20 min):** Distribución de niveles + Chi-cuadrada

Si terminas antes: prueba el Prompt 7 (análisis por criterio de rúbrica) o el Prompt 9 (párrafo de resultados estilo APA).

60 min

Comida (13:00 – 14:00)

Pausa de comida

13:00 – 14:00

Regreso a las 14:00

Decisión estadística

Análisis Estadístico para **demostrar el impacto** de tu Innovación Educativa:

PASO 1

Verifica la Distribución y Varianza de tus datos

Para la distribución de tus datos, puedes utilizar las siguientes pruebas:

Prueba Shapiro-Wilk

= Muestras



50 datos

Prueba Kolmogorov-Smirnov

= Muestras



50 datos



Cuando el resultado de $p > 0.05$ significa que cumples con la normalidad de los datos.

En caso de que cuentes con muestras independientes (**Grupo Control y Experimental**) necesitas conocer la varianza de tus datos, utiliza la siguiente prueba:

Prueba de Levene



Cuando el resultado de $p > 0.05$ significa que las varianzas son iguales.

PASO 2

Selección de la prueba estadística para medir el impacto

2.1 SOLAMENTE 2 GRUPOS
(Control y Experimental).

Prueba a Utilizar:	Normalidad:	Varianza:
Prueba t de Student (muestras independientes)	Datos Normales	Varianza Igual
Prueba t de Welch	Datos Normales	Varianza Diferente
Prueba t de Student (muestras dependientes)	Datos Anormales	Varianza Igual
Prueba U de Mann-Whitney	Datos Anormales	Varianzas Diferentes

Resultado de $p < 0.05$ comprueba la
significancia de tu comparación

2.2 MÁS DE 3 GRUPOS
(Varios grupos control y experimental).

Prueba a Utilizar:	Normalidad:	Varianza:
ANOVA de un factor (solo 1 variable independiente)	Datos Normales	Varianza Igual
ANOVA de dos factores (2 variables independientes)	Datos Normales	Varianza Igual
ANOVA de Welch	Datos Normales	Varianza Diferente
ANOVA de un factor (solo 1 variable independiente)	Datos Anormales	Varianza Igual
ANOVA de dos factores (2 variables independientes)	Datos Anormales	Varianza Igual
Prueba Kruskal Wallis	Datos Anormales	Varianzas Diferentes

Resultado de $p < 0.05$ comprueba la
significancia de tu comparación

2.3 MUESTRAS RELACIONADAS (Pre-Post Test).

Prueba a Utilizar:

Prueba t de Student para
muestras relacionadas

Prueba de Wilcoxon

Normalidad:

Datos Normales

Datos Anormales

Resultado de $p < 0.05$ comprueba la
significancia de tu comparación



Instituto
para el Futuro
de la Educación
Tecnológico de Monterrey

Novus

Infografía: Decisión Estadística. Adaptado de Novus, Instituto para el Futuro de la Educación, 2021.

Módulo 5: Análisis e interpretación de resultados (14:00 – 16:00)

Módulo 5: Lo que vas a construir

Entregable: Informe preliminar de resultados: estructura y mapa de análisis (Plantilla 4)

Hoy construirás:

- ▶ El encabezado y la descripción del proyecto (Secciones 1, 2)
- ▶ El mapa de análisis pre-registrado (Sección 3, en el asíncrono)

Las Secciones 4, 5 y 6 se llenan después del piloto, cuando tengas datos reales.

¿Por qué pre-registrar el análisis?

El sesgo de confirmación:

Cuando ya tienes los datos, es muy difícil no interpretar los resultados ambiguos como favorables a lo que esperabas.

La solución: pre-registro

Antes de ver los datos, documenta:

- ▶ ¿Qué análisis harás para cada objetivo?
- ▶ ¿Qué resultado considerarías éxito?
- ▶ ¿Qué resultado considerarías fracaso?
- ▶ ¿Qué resultado ambiguo anticipas y cómo lo interpretarías?

Si está escrito antes de ver los datos, la interpretación posterior es más creíble.

Análisis descriptivo básico: las herramientas esenciales

Para datos cuantitativos (rúbricas, pre/post-tests):

Análisis	Lo que muestra	Cómo hacerlo
Distribución de niveles pre vs. post	Cuántos estudiantes en cada nivel antes y después	Tabla de conteo + gráfica de barras agrupadas
Cambio en media o mediana del grupo	Tendencia central del grupo antes y después	PROMEDIO() y MEDIANA() en Excel/Sheets
Análisis por criterio de la rúbrica	Qué criterio mejoró más y cuál menos	Tabla de promedios por criterio antes y después

El análisis descriptivo es el punto de partida. Si tienes $N \geq 20$ y/o un grupo de comparación, el análisis inferencial agrega evidencia sobre si el efecto es real y no producto del azar.

Análisis descriptivo básico: datos cualitativos

Para encuestas con preguntas abiertas o entrevistas:

Análisis	Lo que hace	Cuándo usarlo
Codificación inductiva	Leer, identificar ideas recurrentes, agrupar, nombrar	Cuando las categorías no están definidas antes
Análisis temático guiado	Buscar datos sobre los objetivos en el texto	Cuando los temas ya están definidos en los objetivos
Casos atípicos	Identificar respuestas extremas (muy positivas o muy negativas)	Siempre, para entender los límites del resultado

Para 20-30 respuestas abiertas, basta con leer cuidadosamente 2-3 veces y anotar los patrones.

¿Cuándo tiene sentido el análisis inferencial?

El análisis descriptivo (medias, DiD) describe lo que ocurrió en tu muestra. El análisis inferencial pregunta: **¿este resultado podría deberse al azar?**

Condiciones mínimas para que tenga sentido:

Condición	¿Por qué importa?
Al menos 20 estudiantes por grupo	Con menos casos, los tests tienen poca potencia para detectar efectos reales
Datos numéricos (no solo comentarios)	Los tests requieren una escala medible
Diseño definido antes de ver los datos	Si eliges el test después de ver los resultados, el p-value pierde sentido

Un $p\text{-value} < 0.05$ no prueba que tu intervención funciona. Solo dice que el resultado es improbable por azar. El tamaño de efecto dice si el resultado importa en el mundo real.

Árbol de decisión: ¿qué test para qué situación?

¿Cuántos grupos tienes?

Un solo grupo (pre y post)

- ▶ Datos normales o $N \geq 30 \rightarrow$ **t de Student pareada**
- ▶ Datos ordinales o N pequeña $\rightarrow$ **Wilcoxon signed-rank**

Dos grupos (intervención vs. control)

- ▶ Comparar post-scores: datos normales $\rightarrow$ **t independiente**
- ▶ Comparar post-scores: ordinales/asimétricos $\rightarrow$ **Mann-Whitney U**
- ▶ Comparar distribución de niveles $\rightarrow$ **Chi-cuadrada**

Regla práctica: si no sabes si tus datos son normales, usa siempre la versión no paramétrica (Wilcoxon o Mann-Whitney). Pierdes un poco de potencia, pero el resultado es válido en más situaciones.

Para rúbricas: el puntaje total (suma de criterios) puede tratarse como continuo con 20 o más estudiantes. Para analizar cada criterio por separado (escala 1-4 o 1-5), usa Wilcoxon.

Experimentos e Inferencia Causal

Figure 1. Number of Cuban immigrants, by year of migration, 1955-2010





Figure 1. Number of Cuban immigrants, by year of migration, 1955-2010



En 1980, aproximadamente 125,000 inmigrantes —en su mayoría con baja escolaridad— llegaron a Miami desde la Bahía de Mariel, Cuba (“Mariel Boatlift”), en el transcurso de unos pocos meses.

Scarface

David Card (1990): “The Impact of the Mariel Boatlift on the Miami Labor Market”




Table 4
Differences-in-differences estimates of the effect of immigration on unemployment^a

Group		Year		
		1979 (1)	1981 (2)	1981–1979 (3)
<i>Whites</i>				
(1)	Miami	5.1 (1.1)	3.9 (0.9)	–1.2 (1.4)
(2)	Comparison cities	4.4 (0.3)	4.3 (0.3)	–0.1 (0.4)
(3)	Miami-Comparison Difference	0.7 (1.1)	–0.4 (0.95)	–1.1 (1.5)
<i>Blacks</i>				
(4)	Miami	8.3 (1.7)	9.6 (1.8)	1.3 (2.5)
(5)	Comparison cities	10.3 (0.8)	12.6 (0.9)	2.3 (1.2)
(6)	Miami-Comparison Difference	–2.0 (1.9)	–3.0 (2.0)	–1.0 (2.8)

^a Notes: Adapted from Card (1990, Tables 3 and 6). Standard errors are shown in parentheses.

Card (1990)

- ▶ Card concluyó que la llegada masiva de los Marielitos no tuvo efectos significativos sobre los salarios ni sobre las tasas de desempleo de los trabajadores con menores habilidades.

Card (1990)

- ▶ Card concluyó que la llegada masiva de los Marielitos no tuvo efectos significativos sobre los salarios ni sobre las tasas de desempleo de los trabajadores con menores habilidades.
- ▶ Incluso entre los cubanos que habían inmigrado con anterioridad.

Card (1990)

- ▶ Card concluyó que la llegada masiva de los Marielitos no tuvo efectos significativos sobre los salarios ni sobre las tasas de desempleo de los trabajadores con menores habilidades.
- ▶ Incluso entre los cubanos que habían inmigrado con anterioridad.
- ▶ Card sugirió que la capacidad del mercado laboral de Miami para absorber rápidamente a los inmigrantes se debió a su experiencia previa ajustándose a otras oleadas migratorias de gran magnitud.


- ▶ Ethan Lewis (2004) sugiere que los salarios no reaccionan ante choques migratorios locales porque los mercados adaptan la tecnología de producción a la dotación local de factores.

- ▶ Ethan Lewis (2004) sugiere que los salarios no reaccionan ante choques migratorios locales porque los mercados adaptan la tecnología de producción a la dotación local de factores.
- ▶ Bodvarsson et al. (2008) argumentan que una razón por la cual la inmigración no tiene efectos negativos evidentes sobre los salarios de los locales es que los propios inmigrantes, como consumidores, incrementan la demanda de servicios.

- ▶ Ethan Lewis (2004) sugiere que los salarios no reaccionan ante choques migratorios locales porque los mercados adaptan la tecnología de producción a la dotación local de factores.
- ▶ Bodvarsson et al. (2008) argumentan que una razón por la cual la inmigración no tiene efectos negativos evidentes sobre los salarios de los locales es que los propios inmigrantes, como consumidores, incrementan la demanda de servicios.
- ▶ Modelan una economía donde los trabajadores gastan sus ingresos en un bien producido localmente, y prueban su hipótesis reexaminando el caso del Mariel Boatlift, encontrando evidencia sólida de que dicho evento incrementó la demanda laboral.

Entra Borjas (2015)

Logaritmo del salario semanal de personas sin secundaria



El salario de las personas sin secundaria en Miami cayó de forma drástica: entre 10 y 30 por ciento.

Borjas (2015)

- ▶ Al menos **el 60 por ciento de los Marielitos** no había terminado la secundaria.

- ▶ Al menos **el 60 por ciento de los Marielitos** no había terminado la secundaria.
- ▶ Al analizar específicamente los salarios de este grupo con baja escolaridad, se observa que el Mariel Boatlift sí afectó la estructura salarial en Miami.

- ▶ Al menos **el 60 por ciento de los Marielitos** no había terminado la secundaria.
- ▶ Al analizar específicamente los salarios de este grupo con baja escolaridad, se observa que el Mariel Boatlift sí afectó la estructura salarial en Miami.
- ▶ El salario de los trabajadores sin secundaria cayó entre un 10 y un 30 por ciento.



Entran Clemens & Hunt (2017)

Clemens & Hunt (2017)

- ▶ Clemens y Hunt argumentan que la discrepancia entre los análisis de Card y Borjas sobre el Mariel Boatlift se explica por un cambio repentino en la composición racial de los datos utilizados, **específicamente en la Current Population Survey (CPS)**.

Clemens & Hunt (2017)

- ▶ Clemens y Hunt argumentan que la discrepancia entre los análisis de Card y Borjas sobre el Mariel Boatlift se explica por un cambio repentino en la composición racial de los datos utilizados, **específicamente en la Current Population Survey (CPS)**.
- ▶ Esta encuesta se realiza mensualmente, y dos subconjuntos derivados de ella reportan los salarios de los trabajadores (el "March Supplement" y el "Outgoing Rotation Group").



— Miami
- - - Card control cities
— Borjas control cities

Clemens & Hunt (2017)

- ▶ Clemens y Hunt señalan que en 1980 se mejoró la metodología de la CPS para incluir a más hombres afroamericanos con baja escolaridad, quienes previamente habían sido subrepresentados.

- ▶ Clemens y Hunt señalan que en 1980 se mejoró la metodología de la CPS para incluir a más hombres afroamericanos con baja escolaridad, quienes previamente habían sido subrepresentados.
- ▶ A partir de la CPS de 1981, se amplió la cobertura a hombres afroamericanos con escolaridad menor a secundaria, y se redujo la representación relativa de aquellos con secundaria completa (véase figura inferior).

Evaluación de incentivos al desempeño
docente: Lavy (2002)

Contexto y pregunta de investigación

- ▶ En 1996, Israel implementó un programa piloto de bonos grupales por desempeño para docentes de preparatoria.
- ▶ Los bonos se otorgaban a las escuelas cuyos estudiantes obtenían buenos resultados en los exámenes de matriculación.
- ▶ Pregunta de investigación: ¿Los incentivos a docentes mejoran el rendimiento académico del estudiantado?

Diseño experimental

- ▶ Tratamiento: 49 escuelas seleccionadas para participar en el programa de incentivos.
- ▶ Control: 49 escuelas emparejadas de las mismas comunidades, no elegibles para recibir bonos.
- ▶ Selección: Se enfocó en comunidades con **exactamente dos escuelas**.
- ▶ Comparación: Método de Diferencias en Diferencias (DiD) usando puntajes de exámenes antes (1994–95) y después (1996–97) de la intervención.

$$Y_{it} = \alpha + \beta_1 \text{Tratamiento}_i + \beta_2 \text{Post}_t + \delta(\text{Tratamiento}_i \times \text{Post}_t) + \varepsilon_{it}$$

- ▶ Y_{it} : Puntaje de examen del estudiante en la escuela i en el tiempo t
- ▶ Tratamiento_i : Indicador para escuelas tratadas
- ▶ Post_t : Indicador para el periodo posterior a la intervención (1996–1997)
- ▶ δ : Estimador DiD = efecto del programa de incentivos

Identificación e interpretación

- ▶ El diseño garantiza tendencias paralelas mediante el emparejamiento dentro de cada comunidad.
- ▶ La variación exógena proviene de la asignación de política pública.
- ▶ **Supuesto clave:** En ausencia del programa, las tendencias en las escuelas tratadas y de control habrían sido iguales.
- ▶ El coeficiente δ estima el **Efecto Promedio del Tratamiento sobre los Tratados (ATT)**.

Interpretación del estimador DiD

- ▶ En este estudio, la identificación proviene del emparejamiento de escuelas en comunidades con dos planteles:
 - Permite una comparación limpia.
 - Pero limita la validez externa: **no es generalizable** a comunidades más grandes o con estructuras diferentes.
- ▶ Esto refleja el efecto causal del programa de bonos **únicamente para las escuelas tratadas**.
- ▶ Es válido bajo el **supuesto de tendencias paralelas**: en ausencia del tratamiento, ambos grupos habrían seguido la misma tendencia.

Diferencia en diferencias (DiD): aislar el efecto de tu intervención

¿Cuándo usarlo?

Cuando tienes un grupo control (otro grupo sin la intervención) y mediciones antes y después en ambos grupos.

La lógica:

Sin grupo control, no puedes saber si tus estudiantes mejoraron *por tu intervención* o simplemente *porque avanzó el semestre*.

La fórmula:

$$\text{DiD} = (\text{Post_intervención} - \text{Pre_intervención}) - (\text{Post_control} - \text{Pre_control})$$

Lo que DiD mide: el cambio en tu grupo que **no** hubiera ocurrido de todas formas.

Ejemplo — Rúbrica de argumentación escrita (escala 4–16, 4 criterios × 1–4):

Descarga `rubrica_argumentacion.csv` para replicar este análisis.

Grupo	Pre (media)	Post (media)	Cambio
Intervención (n = 23)	9.5	10.8	+1.3
Control (n = 19)	9.4	9.2	−0.3
DiD			+1.6

Interpretación: la intervención generó **1.6 puntos adicionales** de mejora en la rúbrica, más allá del cambio que hubiera ocurrido de todas formas.

Paso 1 — En Excel o Sheets (5 minutos):

1. Abre `rubrica_argumentacion.csv` (columnas: `estudiante_id`, `grupo`, `pre`, `post` + criterios individuales)
2. En una celda vacía: `=PROMEDIO(SI(B2:B46="intervencion",J2:J46))`
(Ctrl+Shift+Enter)
3. Repite para `post` y para `control`
4. $DiD = (Post_I - Pre_I) - (Post_C - Pre_C)$
5. Inserta gráfica de barras agrupadas: `Pre` y `Post` por grupo

DiD con Claude Code

Paso 2 — Pídele a Claude Code que haga el análisis:

Abre Claude Code y escribe exactamente esto:

Tengo datos de un piloto educativo en el archivo `rubrica_argumentacion.csv`. Las columnas son: `estudiante_id`, `grupo` (intervencion / control), `semestre`, `sexo`, `c1_pre` a `c4_pre` (criterios de la rúbrica antes), `pre` (total antes), `c1_post` a `c4_post` (criterios después), `post` (total después). Por favor:

1. Calcula la media de pre y post por grupo, ignorando los valores faltantes en post. 2. Calcula el cambio ($\text{post} - \text{pre}$) por grupo. 3. Calcula la Diferencia en Diferencias (DiD). 4. Muestra una gráfica de barras con pre y post por grupo. 5. Muestra qué criterio de la rúbrica tuvo la mayor y la menor mejora en el grupo intervención. 6. Escribe una oración de interpretación de los resultados.

Claude Code generará el análisis completo, la gráfica y la interpretación lista para copiar al informe.

Tamaño de efecto: la d de Cohen

Indica si una diferencia es grande o pequeña, **independientemente del p-value y del N.**

d	Tamaño del efecto	Referencia intuitiva
0.2	Pequeño	Difícil de notar sin datos
0.5	Mediano	Visible con atención
0.8	Grande	Evidente a simple vista
1.0+	Muy grande	Poco frecuente en un semestre

Con N pequeña (20-30 estudiantes), el p-value puede no llegar a 0.05 aunque el efecto sea real. La d de Cohen no depende del N: es tu evidencia más honesta.

t de Student pareada

Compara el mismo grupo antes y después de la intervención.

¿Qué mide? Si la diferencia entre las medias de pre y post es mayor de lo que esperarías por azar.

Cuándo usarla:

- ▶ Un solo grupo con medición pre y post
- ▶ Datos aproximadamente normales o $N \geq 30$
- ▶ Escala continua (suma de rúbrica, calificación)

Produce: estadístico t, grados de libertad, p-value. Complementa siempre con d de Cohen.

Con $N = 20-30$ y datos de rúbrica (escala 4-16), la t pareada es válida. Si tienes dudas sobre normalidad, usa Wilcoxon como verificación.

Wilcoxon signed-rank

La alternativa no paramétrica a la t pareada.

¿Qué mide? Si las diferencias individuales (post – pre) tienden a ser positivas o negativas de forma sistemática, sin asumir distribución normal.

Cuándo usarla:

- ▶ Un solo grupo, escala ordinal o Likert por ítem
- ▶ $N < 30$ o distribución claramente asimétrica
- ▶ Como verificación robusta de la t pareada

Produce: estadístico W, p-value. Tamaño de efecto: $r = Z/\sqrt{N}$.

Para rúbricas con menos de 30 estudiantes, Wilcoxon es la elección más conservadora y defensible. Reporta junto con la mediana del cambio.

t de Student independiente

Compara las medias de dos grupos distintos (intervención vs. control) en el mismo momento.
¿Qué mide? Si la diferencia de medias entre grupos en el post-test es mayor de lo que esperarías por azar.

Cuándo usarla:

- ▶ Dos grupos distintos (no el mismo grupo antes/después)
- ▶ Datos aproximadamente normales, $N \geq 20$ por grupo
- ▶ Escala continua

Produce: estadístico t, p-value, d de Cohen para grupos independientes.

No confundas con la t pareada. Esta compara grupos distintos, no el mismo grupo en dos momentos.

Mann-Whitney U

La alternativa no paramétrica a la t independiente.

¿Qué mide? Si los valores de un grupo tienden a ser consistentemente mayores que los del otro, sin asumir distribución normal.

Cuándo usarla:

- ▶ Dos grupos distintos con escala ordinal o asimétrica
- ▶ $N < 20$ por grupo o como verificación robusta de la t independiente
- ▶ Cuando los grupos tienen tamaños muy distintos

Produce: estadístico U, p-value. Tamaño de efecto: $r = Z/\sqrt{N}$.

Chi-cuadrada

Compara distribuciones de categorías, no medias.

¿Qué mide? Si la proporción de estudiantes en cada nivel (Básico / Sólido / Avanzado) cambió entre pre y post, o difiere entre grupos.

Cuándo usarla:

- ▶ Tu umbral de éxito está definido en niveles, no en puntos
- ▶ Quieres saber cuántos estudiantes cruzaron un umbral, no cuánto mejoró la media
- ▶ Comparar distribuciones entre grupos

Produce: estadístico χ^2 , p-value, tabla de contingencia.

Convierte primero los puntajes en categorías: "En desarrollo" (4-7), "Satisfactorio" (8-11), "Avanzado" (12-16). Luego corre la prueba sobre esas categorías.

Tests con Claude Code: un solo grupo (pre vs. post)

t de Student pareada / Wilcoxon signed-rank

Tengo los datos en `rubrica_argumentacion.csv`. Para el grupo "intervencion", compara las columnas pre y post usando una prueba t pareada y, como alternativa, la prueba de Wilcoxon signed-rank. Reporta el estadístico, el p-value y el tamaño de efecto (d de Cohen para la t, r para Wilcoxon). Interpreta el resultado en una oración.

Tests con Claude Code: dos grupos (intervención vs. control)

Mann-Whitney U / t independiente

Con los mismos datos, compara las puntuaciones post entre "intervencion" y "control" usando Mann-Whitney U y también una t de Student independiente. Reporta p-value y tamaño de efecto (d de Cohen). Ignora los valores faltantes en post.

Chi-cuadrada

Crea una variable "nivel_pre" y "nivel_post" con tres categorías: "En desarrollo" (4-7), "Satisfactorio" (8-11), "Avanzado" (12-16). Para el grupo intervencion, corre una prueba chi-cuadrada para comparar la distribución de niveles entre pre y post. Muestra la tabla de contingencia y el p-value.

Regresión lineal simple: controlar el punto de partida

Problema frecuente: los dos grupos no son idénticos en el pre-test. Si el grupo intervención empezó con ventaja, el DiD podría sobrestimar el efecto de la intervención.

Solución: usar el pre-test como covariable

Con `rubrica_argumentacion.csv`, ajusta una regresión lineal donde la variable dependiente es "post" y las variables independientes son "pre" y "grupo" (0 = control, 1 = intervencion).

Reporta el coeficiente de "grupo" con su intervalo de confianza del 95% y su p-value.

Interpreta: ¿cuántos puntos adicionales predice el modelo para el grupo intervención, controlando el nivel inicial?

Si el coeficiente de "grupo" es positivo y significativo, el efecto de la intervención persiste incluso después de controlar por diferencias previas entre grupos.

Subgrupos: ¿el efecto se mantiene en todos?

Dos comparaciones útiles en nuestro dataset:

Variable de subgrupo	Grupos	Test a usar
Semestre	3, 5, 7	Kruskal-Wallis (3 grupos)
Sexo	F, M	Mann-Whitney U (2 grupos)

Con `rubrica_argumentacion.csv`, calcula la d de Cohen del cambio (post - pre) del grupo intervencion separado por semestre (3, 5, 7).

Luego repite separado por sexo (F, M).

¿El efecto es consistente entre subgrupos o hay diferencias notables?

Genera una gráfica de barras con el cambio promedio por subgrupo.

Si d varía mucho entre subgrupos (p. ej. $d = 1.2$ para semestre 3 y $d = 0.1$ para semestre 7), la intervención tiene efectos diferenciales. Eso es información valiosa, no un fracaso.

Visualización: qué gráfica para qué análisis

Qué quieres mostrar	Gráfica recomendada	Evita
Cambio en media pre vs. post por grupo	Barras agrupadas con valores encima	Gráfica de líneas con un solo grupo
Distribución de niveles pre vs. post	Barras apiladas (%)	Pastel: oculta las diferencias absolutas
Tendencia durante el semestre	Línea de tiempo (medición 1, 2, 3...)	Barras: no comunica tendencia
Comparar variabilidad entre grupos	Boxplot	Solo medias: oculta la dispersión
Efecto por criterio de rúbrica	Barras horizontales ordenadas	Tabla de números sola

Una gráfica bien elegida reemplaza tres párrafos de texto. En tu mapa de análisis (Plantilla 4, Sección 3), define la gráfica antes de tener los datos.

De tus resultados a lenguaje para NOVUS

Lo que dicen tus estadísticas: > “La prueba de Wilcoxon signed-rank mostró una diferencia significativa ($W = 187$, $p = 0.003$). La d de Cohen fue 0.69.”

Lo que debe decir tu propuesta: > “El 30 % de los estudiantes del grupo intervención mejoró de nivel Básico a Sólido en la rúbrica de argumentación, frente al 5 % del grupo control. El tamaño del efecto fue mediano-grande ($d = 0.69$), un resultado sólido para una innovación de un semestre.”

Las tres reglas de traducción:

1. Reporta porcentajes de estudiantes y cambios de nivel, no solo medias
2. Nombra el tamaño del efecto en palabras (pequeño / mediano / grande), no solo el número
3. Siempre compara con el grupo control o con el estado previo

Para NOVUS: los evaluadores de la convocatoria no son estadísticos. Lo que convence es “cuántos estudiantes mejoraron y cuánto”, no el p -value.

Significancia práctica vs. estadística

Una distinción que a menudo no se explica:

	Significancia estadística	Significancia práctica
¿Qué mide?	Si el resultado probablemente no es por azar	Si el resultado importa en el mundo real
¿Qué requiere?	Tamaño de muestra grande, análisis inferencial	Juicio sobre qué cambio tiene valor pedagógico
Ejemplo	“El p-value es 0.04”	“El 25 % de los estudiantes pasó de nivel 1 a nivel 2”
¿Cuál importa más aquí?	La estadística importa menos con N pequeñas	La práctica importa siempre

Un resultado estadísticamente significativo puede ser pedagógicamente irrelevante. Y viceversa.

Cómo reportar resultados negativos o mixtos

El error más común: solo reportar lo que funcionó.

Por qué importa reportar los negativos:

- ▶ Los resultados negativos son información sobre qué NO funciona, tan valiosos como los positivos
- ▶ Si se ocultan, los colegas que repliquen la intervención enfrentarán los mismos problemas
- ▶ Los evaluadores de convocatorias (NOVUS) valoran más un reporte honesto que uno que parece demasiado perfecto

Formato:

“Los datos muestran X [dato concreto], lo que sugiere Y [interpretación], con la limitación de Z [honestidad sobre qué no se puede afirmar].”

Actividad: Estructura del informe (14:45 – 15:45)

Plantilla 4, Encabezado y Sección 2

Trabajo individual: 60 minutos

1. **Encabezado (5 min):** Datos generales del proyecto
2. **Sección 2.1 (20 min):** Contexto y necesidad educativa
3. **Sección 2.2 (15 min):** La intervención desde la perspectiva del estudiante
4. **Sección 2.3 (20 min):** Metodología: diseño, participantes, instrumentos

La Sección 3 (mapa de análisis) la completan en el asíncrono de hoy.

60 min

Retroalimentación rápida: descripción del proyecto (15:45 – 16:00)

Mismo par: 15 minutos

- ▶ ¿Alguien que no conoce el proyecto puede entender qué hiciste y por qué?
- ▶ ¿La metodología es lo suficientemente clara para que alguien más pueda replicarla?
- ▶ ¿Hay afirmaciones de causalidad que el diseño no soporta?

15 min

**Bloque asincrónico (16:00 –
18:00)**

Tarea asincrónica: Mapa de análisis pre-registrado

Abre la Plantilla 4 y ve a la Sección 3: Mapa de análisis

Esta es la tarea más importante del asíncrono.

Lo que harás (aprox. 60-75 min):

Para cada objetivo:

1. Define qué análisis harás (tabla, gráfica, comparación)
2. Especifica qué resultado considerarías éxito (tu umbral)
3. Especifica qué resultado considerarías fracaso del que aprender
4. Anticipa qué resultado ambiguo podrías obtener y cómo lo interpretarías

Complétalo antes de ver cualquier dato. Eso es el pre-registro.

Tiempo sugerido: 60-75 min

Lo que tienes mañana al llegar

Llegarás el viernes con:

- ▶ Plantilla 1: Instrumento revisado
- ▶ Plantilla 2: Cadena de evaluación + línea base
- ▶ Plantilla 3: Plan de pilotaje
- ▶ Plantilla 4: Descripción del proyecto + mapa de análisis

Mañana:

- ▶ Presentas tu proyecto al grupo: 10 minutos + 5 de retroalimentación
- ▶ Cierras el curso con compromisos concretos para los próximos 30 días

Prepara tu presentación esta noche. La estructura está en el slide de apertura del Día 3.

Hasta mañana a las 9:00.